

Course-ID:	BA-INF 051
Course:	MLAI Projektgruppe
Term:	Sommersemester 2024
Supervisor(s):	Fouad Alkhoury
Students:	Rouy Alfahel: 3389227

Verwendung von maschinellem Lernen zur Vorhersage von Zugverspätungen

Rouy Alfahel

September 20, 2024

Abstract

Diese Arbeit beschäftigt sich mit der Analyse und Vorhersage von Zugverspätungen unter Verwendung von maschinellen Lernmodellen. Ziel ist es, die Genauigkeit des Prognosemodells Random Forest (RF) zu evaluieren. Hierzu wurden umfangreiche Daten zu Zugbewegungen, betrieblichen Abläufen und externen Faktoren wie Wetterbedingungen aus dem Jahr 2022 in Polen analysiert. Die Methodik umfasst die Vorverarbeitung der Daten, die Auswahl relevanter Einflussfaktoren und die Implementierung des Vorhersagemodells.

1 Introduction

Die Vorhersage von Zugverspätungen ist eine zentrale Herausforderung im Bahnverkehr, da Verspätungen sowohl die Zufriedenheit der Fahrgäste beeinträchtigen als auch den Betriebsablauf stören können. Maschinelle Lernmodelle wie Random Forests (RF) bieten vielversprechende Ansätze, um diese Vorhersagen zu verbessern. Random Forests nutzen eine Vielzahl von Entscheidungsbäumen, um Zusammenhänge in den Daten zu identifizieren und daraus Vorhersagen abzuleiten. In dieser Arbeit wird das Modell mithilfe von Daten zu Zugbewegungen, Betriebsabläufen und externen Faktoren wie Wetterbedingungen, die im Jahr 2022 in Polen erhoben wurden, trainiert und getestet. (Alfahel, 2024)

Dabei wird der Offline-Modus verwendet, um die Vorhersagen zu erstellen. Der Offline-Modus bedeutet, dass die Modelle auf Basis historischer Daten trainiert werden, ohne kontinuierlich neue Daten zu integrieren. Figure 1 veranschaulicht diesen Prozess: Die Kreise repräsentieren die erwarteten (schwarz) und tatsächlichen (weiß) Ankunftszeiten




Figure 1: offline prediction model (Hauck and Kliewer, 2020)

	datetime	id	carrier	date	connection	arrival	delay	name
0	2022-05-16 00:00:00	41002/3 (102) POLONIA	PKP Intercity	2022-05-15	Bohumin - Warszawa Wschodnia	21:31	162 min	Warszawa Zachodnia
1	2022-05-16 00:00:00	91888/9 (102)	Koleje Mazowieckie	2022-05-16	Siedlce - Warszawa Zachodnia	00:15	0 min	Warszawa Zachodnia

Figure 2: Ausschnitt aus dem Datensatz "Polish Railroads Dataset"(Alfahel, 2024)

	id	connection	name	temperatur	Delay Type	Arriva	Koleje Dolnośląskie	Koleje Mazowieckie	Koleje Wielkopolskie	Koleje Śląskie	PKP Intercity	PKP SKM w Trójmieście Sp. z o.o.	POLREGIO Sp. z o.o.	SKM Warszawa	Łódzka Kolej Aglomeracyjna	hour_of_day	day_of_week	minutes	delay_int	
205398	0.018122	0.320926	92	15.0	0	0	0	0	0	0	0	0	0	0	0	1	17	6	19	0
102799	0.585452	0.387324	86	18.2	1	0	1	0	0	0	0	0	0	0	0	9	3	13	2	0
131747	0.841430	0.790744	76	14.7	1	0	0	1	0	0	0	0	0	0	0	6	4	46	1	0
323886	0.259376	0.520121	51	19.8	1	0	0	0	0	0	1	0	0	0	0	13	3	9	1	0
168819	0.243896	0.288732	81	16.4	1	0	0	0	0	0	1	0	0	0	0	8	5	17	1	0
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
397069	0.356280	0.238431	32	10.1	1	0	0	0	0	0	0	0	1	0	0	21	5	24	4	0
296529	0.530078	0.873239	1	16.1	2	0	0	0	0	0	1	0	0	0	0	16	2	54	19	0
303058	0.513843	0.844064	17	15.2	0	0	0	0	0	0	0	1	0	0	0	19	2	3	0	0
399093	0.690410	0.988934	90	10.0	1	0	0	0	0	0	1	0	0	0	0	1	6	59	2	0
191046	0.630632	0.914487	43	10.5	0	0	0	0	1	0	0	0	0	0	0	5	6	15	0	0
125928 rows × 19 columns																				

125928 rows x 19 columns

Figure 3: Ausschnitt aus dem bereinigten "Polish Railroads Dataset" Datensatz"(Alfahel, 2024)

für verschiedene Bahnhöfe (A, B, C, D, N) über mehrere Tage hinweg. Das Ziel der Studie ist es, präzise Vorhersagen für Tag x zu treffen, basierend auf den historischen Ankunftszeiten und den vorherigen Zugbewegungen.(Hauck and Kliewer, 2020)

2 Die verwendeten Datensätze

Für die Analyse der Zugverspätungen wird der "Polish Railroads Dataset" verwendet. Der Polish Railroads Dataset umfasst insgesamt 3.718.170 Zeilen und 8 verschiedene Merkmale. Dazu gehören der Zeitstempel, zu dem die Daten erfasst wurden, die Zug-ID, der Name des Beförderers, das Abfahrtsdatum des Zuges, der Start- und Zielbahnhof, die geplante Ankunftszeit am Zielort, die aktuell geschätzte Verspätung und der Name des Bahnhofs. Figure 2 gibt einen Einblick in die Struktur dieses Datensatzes und veranschaulicht die Art der darin enthaltenen Informationen.(Alfahel, 2024)

3 Datenbereinigung

Datenbereinigung spielt eine zentrale Rolle in der Datenanalyse, indem sie sicherstellt, dass die Qualität der Daten hoch genug ist, um verlässliche Ergebnisse zu erzielen. Fehlerhafte oder ungenaue Daten, wie sie beispielsweise durch doppelte Einträge, inkonsistente Formate oder fehlerhafte Eingaben entstehen, können die Analyseergebnisse verfälschen. Daher ist es essenziell, solche Fehler zu identifizieren und zu beheben. Im Rahmen der Datenverarbeitung des Polish Railroads Dataset wurden mehrere wichtige Schritte durchgeführt, um die Daten für die Analyse vorzubereiten und relevante Infor-

mationen hinzuzufügen. Zunächst wurden die Zug_IDs und die Verbindungsinformationen in unterschiedliche numerische Kategorien umgewandelt. Diese Kategorien wurden anschließend mit dem MinMaxScaler auf Werte zwischen 0 und 1 skaliert, um eine konsistente und vergleichbare Skala für maschinelles Lernen zu gewährleisten. Darüber hinaus wurde der Name des aktuellen Bahnhofs in numerische Werte konvertiert. Ein weiterer wichtiger Schritt bestand darin, alle Duplikate im Datensatz zu entfernen, um sicherzustellen, dass jede Kombination von ID, Verbindung, Verspätung und anderen relevanten Attributen einzigartig ist. Dies trug dazu bei, die Integrität der Analyse zu gewährleisten und doppelte Einträge zu vermeiden. Zusätzlich wurden alle Zeilen ausgeschlossen, in denen die Ankunftszeit den Wert "Nie dotyczy" aufwies. Dieser Wert bedeutete "Nicht zutreffend" oder "Nicht relevant". Durch das Entfernen dieser Zeilen wurde sichergestellt, dass nur valide und relevante Daten in die Analyse einfließen. Nach dem Entfernen der Duplikate wird das Feld 'datetime' entfernt, da der Zeitpunkt der Probenentnahme für die Vorhersage keine Rolle spielt. Die Felder 'date' und 'arrival' wurden in ein einheitliches datetime-Format umgewandelt und anschließend in drei neue numerische Merkmale aufgeteilt: 'hour_of_day', 'day_of_week' und 'minutes'. Eine wichtige Ergänzung des Datensatzes war die Einbindung von Wetterinformationen. Mithilfe der Webseite Open-Meteo wurden Temperaturdaten für den Zeitraum vom 15. Mai bis 30. Mai 2022 für insgesamt 95 verschiedene Bahnhöfe heruntergeladen. Diese Daten wurden in den Datensatz integriert, wobei die Zeitangaben auf volle Stunden gerundet wurden. So wurden beispielsweise alle Zeiten zwischen 11:00 und 11:59 als 11:00 Uhr behandelt. Zur Kategorisierung der Verspätungen wurde eine neue Spalte „Delay Type“ eingeführt, die jeder Zeile basierend auf der Dauer der Verspätung einen Wert von 0 bis 6 zuweist. Dabei repräsentiert der Wert 0 eine minimale Verspätung von 0 bis 4 Minuten, während 1 für eine Verspätung von 5 bis 10 Minuten steht. Der Wert 2 umfasst Verspätungen zwischen 11 und 15 Minuten, 3 steht für 16 bis 20 Minuten, und 4 erfasst Verspätungen von 21 bis 40 Minuten. Für längere Verzögerungen ist der Wert 5 für 41 bis 60 Minuten reserviert, während 6 Verspätungen von mehr als 60 Minuten bezeichnet. Diese Einteilung ermöglicht eine präzise Differenzierung der Verspätungszeiten und erleichtert so die Analyse und das Verständnis der Daten. Die Ursachen für die Verspätungen sind vielfältig. Baustellen führen im Durchschnitt zu Verzögerungen von 5 bis 15 Minuten, während das Warten auf Anschlusszüge oft kürzere Verspätungen von 1 bis 5 Minuten verursacht. Witterungsbedingungen wie starkes Regen oder Schnee können zu Verspätungen von 10 bis 30 Minuten oder manchmal sogar länger führen. Technische Probleme, sei es an den Zügen selbst oder an der Infrastruktur, bewegen sich meist im Bereich von 5 bis 15 Minuten. Unfälle und Notfälle können dagegen große Verzögerungen von über 30 Minuten bis zu mehreren Stunden mit sich bringen. Auch die Streckenauslastung und Engpässe spielen eine Rolle, wobei die Verspätungen stark davon abhängen, welche Strecke und Tageszeit betroffen sind. Externe Faktoren wie Vandalismus oder Personen auf den Gleisen führen im Durchschnitt zu Verspätungen von 5 bis 20 Minuten. Diese Zeitangaben sind jedoch nur Durchschnittswerte und können je nach Situation variieren (ZDF Heute, 2024) (Deutsche Bahn, 2024). Indem wir die Verspätungen und ihre Gründe auf diese Weise erfassen und kategorisieren, können wir Muster besser erkennen und die Betriebsabläufe gezielter verbessern. Des Weiteren wurden die verschiedenen Beförderer (Carrier) in separate Spalten umgewandelt, wobei jede Spalte anzeigt, ob die jeweilige Zugreise zu dem betreffenden Carrier gehört (Wert 1) oder nicht (Wert 0). Dies ermöglicht eine einfache Einbindung dieser Informationen in Modelle. Schließlich wurde die Verspätungszeit, die ursprünglich als String vorlag (z. B. "5 min"), in einen Integer-Wert konvertiert, um die Daten besser verarbeiten zu können. Dies erleichtert die Durch-




Figure 4: Boxplot für Verzögerungen aus dem Datensatz "Polish Railroads Dataset"(Alfahel, 2024)

führung von Berechnungen und die Anwendung von Modellen, die auf numerischen Eingaben basieren. Figure 3 veranschaulicht den Datensatz nach diesen umfassenden Vorbereitungs- und BereinigungsSchritten. In der Tabelle sind die verschiedenen Spalten sichtbar, darunter die neu eingefügten Wetterdaten, die „Delay Type“-Kategorisierung, sowie die umgewandelten und skalierten numerischen Werte für Zug-IDs, Verbindungen und Beförderer. Es zeigt klar, wie die Daten strukturiert wurden, um die Analysefähigkeit zu maximieren und den Datensatz für weiterführende Modellierungen und Analysen optimal vorzubereiten.

4 Datenanalyse des "Polish Railroads Dataset"

4.1 Boxplot für Verzögerungen

Ein wichtiger Teil der Datenanalyse ist die Erstellung eines Boxplots, um die Verteilung der Zugverspätungen besser zu verstehen. Der Boxplot (Figure 4) zeigt, dass der Großteil der Verspätungen bei 0 Minuten liegt, was bedeutet, dass mehr als die Hälfte der Züge pünktlich ankommt – konkret waren das ungefähr 250 000 Züge, wie auch im Histogramm (Figure 5) zu sehen ist. Das Histogramm verdeutlicht, dass es eine sehr hohe Anzahl an Zügen gibt, die ohne Verspätung ankommen, während die Anzahl der Züge mit Verspätungen über 0 Minuten schnell abnimmt. Nur wenige Züge haben längere Verspätungen von über 20 Minuten, was darauf hindeutet, dass die meisten Züge ihre geplanten Ankunftszeiten einhalten. Das obere Quartil liegt bei 2 Minuten, was bedeutet, dass 75 % der Züge eine maximale Verspätung von 2 Minuten aufweisen. Der durchschnittliche Wert der Verspätungen beträgt etwa 4,47 Minuten, was darauf hinweist, dass es einige Züge mit deutlich längeren Verspätungen gibt, die den Durchschnitt nach oben ziehen. Der Boxplot zeigt, dass die meisten Züge nur geringe Verspätungen hatten und in einem engen Bereich lagen. Es gab allerdings auch einige Ausreißer, bei denen die Verzögerungen bis zu 200 Minuten und in wenigen Fällen sogar zwischen 200 und 1400 Minuten betrugen. Solche extremen Verspätungen können die Ergebnisse der Analyse stark verzerren.




Figure 5: Verteilung der Zugverspätungen in Minuten: Häufigkeit der Ankünfte im Zeitverlauf(Alfahel, 2024)

Deshalb wurden alle Züge mit einer Verspätung von mehr als 83 Minuten als Ausreißer betrachtet und entfernt.(Alfahel, 2024)

4.2 Zugverspätungen im Zusammenhang mit Wetterbedingungen und Date-time

Figure 6 zeigt eine Streudiagramm-Visualisierung der Beziehung zwischen der Temperatur und der Verspätungsdauer von Zügen im Zeitraum vom 15.05 bis 30.05.2022. Auf der x-Achse ist das Datum der Ankunft zu sehen, während die y-Achse die gemessene Temperatur in Grad Celsius darstellt. Die Datenpunkte sind nach der Verspätungsdauer in verschiedene Farbkategorien unterteilt: 0-25, 25-50, 50-75 und 75-100 Minuten. Das Diagramm verdeutlicht, dass es eine erhebliche Variabilität in den Verspätungen über den dargestellten Zeitraum gibt, wobei die meisten Verspätungen im Bereich von 0-25 Minuten (blau) liegen. Auffällig ist jedoch, dass die größten Verspätungen (orange und rot), insbesondere in den Kategorien 50-75 und 75-100 Minuten, zwischen dem 21. Mai und dem 25. Mai auftraten. Diese Häufung von Verspätungen könnte auf mehrere Faktoren zurückzuführen sein. Besonders bemerkenswert ist, dass die meisten dieser längeren Verspätungen in einem Zeitraum mit merklichen Temperaturschwankungen auftraten. Dies deutet darauf hin, dass extreme Wetterbedingungen, wie stark schwankende Temperaturen, einen Einfluss auf die Pünktlichkeit der Züge gehabt haben könnten. Zusätzlich zu den Wetterbedingungen könnten jedoch auch andere Faktoren wie technische Probleme, Bauarbeiten oder außergewöhnliche Verkehrsbedingungen eine Rolle gespielt haben.(Alfahel, 2024)

5 Random Forest

Random Forest ist ein ensemblebasiertes Lernverfahren, das aus vielen Entscheidungsbäumen besteht. Jeder Baum wird auf einer zufälligen Teilmenge des Datensatzes trainiert, die durch Bootstrapping erzeugt wird, das heißt, es werden Stichproben mit Zurücklegen aus dem Originaldatensatz gezogen. Durch dieses Verfahren erhält jeder Baum einen leicht unterschiedlichen Datensatz, was die Varianz der Vorhersagen reduziert und eine höhere Generalisierungsfähigkeit des Modells ermöglicht. Ein zentraler Aspekt des Random Forests ist, dass an jedem Knoten eines Entscheidungsbaums nicht alle Merkmale,




Figure 6: Analyse von Zugverspätungen im Zusammenhang mit Wetterbedingungen und Datetime(Alfahel, 2024)

sondern nur eine zufällig ausgewählte Teilmenge der Merkmale betrachtet wird. Dies verhindert, dass einzelne Merkmale übermäßig dominieren, und reduziert die Korrelation zwischen den Bäumen. Ein wichtiger Bestandteil der Entscheidungsfindung in einem Baum ist die Wahl des besten Merkmals für den Split an einem Knoten. Dies geschieht durch die Berechnung des Gini-Index, der die Reinheit der Aufteilung misst. Der Gini-Index gibt an, wie gut ein Merkmal die Klassen trennen kann. Er wird wie folgt berechnet:

$$\text{Gini}(\mathbf{p}) = 1 - \sum_{i=1}^n p_i^2$$

p_i die Wahrscheinlichkeit ist, dass ein Element zur Klasse i gehört. Der Gini-Index ist ein Maß für die Ungleichheit einer Verteilung. Ein Wert von 0 bedeutet perfekte Reinheit (alle Elemente gehören zur gleichen Klasse), während höhere Werte auf eine größere Vermischung der Klassen hinweisen. Der Split mit dem niedrigsten Gini-Wert wird gewählt, um die bestmögliche Trennung der Daten zu erreichen. In der Vorhersagephase kombiniert der Random Forest die Ergebnisse aller Entscheidungsbäume. Bei Klassifikationsaufgaben wird die Vorhersage durch Mehrheitsabstimmung (Voting) getroffen, d. h., die Klasse, die von den meisten Bäumen gewählt wird, wird als endgültige Vorhersage ausgegeben. Bei Regressionsaufgaben wird der Durchschnitt der Vorhersagen aller Bäume berechnet.(Wikipedia, 2024)

5.1 Implementierung im Polish Railroads Dataset

Für die Implementierung des Random-Forest-Algorithmus im Rahmen der Analyse wurde ein strukturierter Ansatz in mehreren Schritten verfolgt. Zunächst erfolgte die Datenaufbereitung durch Bereinigung und Umwandlung relevanter Informationen, wie Zug-IDs, Verbindungen, Wetterdaten und Verspätungszeiten, in ein geeignetes Format. Um

Table 13

Performance comparison of the different models for the three delay scenarios.

Methods	Railway catenary failure			ATP system failure			Object Intrusion		
	R^2	RMSE	MAE	R^2	RMSE	MAE	R^2	RMSE	MAE
ANN	0.9534	1.99	1.43	0.9856	2.77	2.03	0.9610	2.49	1.63
KNN	0.9365	3.46	2.01	0.9753	4.24	2.99	0.9468	3.01	2.22
SVR	0.9674	1.56	0.97	0.9897	2.31	1.86	0.9634	2.12	1.89
DELM	0.9724	1.59	0.92	0.9903	1.96	1.72	0.9749	1.82	1.50
GBDT	0.9448	2.25	1.56	0.9830	2.89	2.36	0.9530	2.73	2.02
RF	0.9663	1.76	1.14	0.9901	2.20	1.70	0.9675	1.99	1.63
BO-XGBoost	0.9768	1.41	0.89	0.9903	1.63	1.43	0.9778	1.75	1.50

Figure 7: Performance comparison of the different models for the three delay scenarios(Shi et al., 2021)

sicherzustellen, dass alle Merkmale auf einer vergleichbaren Skala liegen, wurde eine Standardisierung der Daten durchgeführt. Anschließend erfolgte eine Aufteilung des Datensatzes in Trainings- und Testdaten, wobei 70 % der Daten für das Training und 30 % für die Validierung verwendet wurden. Zur Optimierung des Modells wurde eine Hyperparameter-Optimierung mittels Grid Search und einer 5-fachen Kreuzvalidierung durchgeführt. Dabei wurden verschiedene Parameterkombinationen getestet, um die beste Kombination für die Vorhersage des "Delay Type" zu ermitteln. Untersucht wurden folgende Hyperparameter: max_features = 7, 15, 20, min_samples_split = 2, 20, 40, n_estimators = 200, 400, 500, 1000 und max_depth = None, 4, 8. Das Ziel bestand darin, die beste Parameterkombination zu identifizieren, um die Leistungsfähigkeit des Modells zu maximieren. Das optimierte Random-Forest-Modell wurde auf den Trainingsdaten trainiert, um möglichst präzise Vorhersagen für "Delay Type" zu treffen. Die anschließende Evaluierung auf den Testdaten erfolgte anhand verschiedener Metriken wie Genauigkeit, F1-Score, Präzision und Recall, um die Vorhersagegenauigkeit und Zuverlässigkeit des Modells zu bewerten. Diese Analysen zeigten, wie gut das Modell in der Lage war, die verschiedenen Kategorien des "Delay Type" korrekt vorherzusagen und welche Faktoren dabei eine besonders wichtige Rolle spielten.(Alfahel, 2024)

5.2 "Delay Type" vs "delay_int"

Um die Aussagekraft der Analyse zu verbessern und sie praxisnäher zu gestalten, wurde die ursprüngliche Zielvariable "delay_int" (genaue Verspätungszeit in Minuten) durch die neue Zielvariable "Delay Type" (Verspätungskategorie) ersetzt. Dies geschah, weil es für die Bahnreisende keinen wesentlichen Unterschied macht, ob ein Zug eine Verspätung von 20 oder 21 Minuten hat. Für die Bahnreisende ist es wichtiger, das Zeitintervall der Verspätung zu kennen, beispielsweise ob der Zug weniger als 15 Minuten, zwischen 15 und 30 Minuten oder mehr als 30 Minuten verspätet ist. Die Ergebnisse der Vorhersage mit der ursprünglichen Zielvariable "delay_int" waren zudem nur mittelmäßig. Während in einer vergleichbaren Studie das Random-Forest-Modell (Figure 7) für das Szenario "Railway catenary failure" sehr gute Werte erzielte, nämlich ein R^2 von 0,9663, einen RMSE von 1,76 und einen MAE von 1,14, sowie für das Szenario "ATP system failure" ein R^2 von 0,9901, einen RMSE von 2,20 und einen MAE von 1,70 und für das Szenario "Object Intrusion" ein R^2 von 0,9675, einen RMSE von 1,99 und einen MAE von 1,63, lagen unsere Modellwerte im Vergleich deutlich schlechter.(Shi et al., 2021) Konkret zeigte mein Modell einen R^2 -Wert von 0,57, einen Mean Absolute Error (MAE) von 2,74, einen Mean Squared Error (MSE) von 36,41 und einen Root Mean Squared Error (RMSE) von 6,03. Diese Werte verdeutlichten eine erhebliche Abweichung zwischen den vorherge-

sagten und den tatsächlichen Verspätungszeiten, was auf eine begrenzte Genauigkeit des Modells hinweist.(Alfahel, 2024) Angesichts dieser vergleichsweise mäßigen Ergebnisse wurde beschlossen, die Zielvariable "delay_int" durch "Delay Type" zu ersetzen. Diese Änderung verbessert die Vorhersagequalität und macht die Ergebnisse für die praktische Anwendung relevanter, da sie sich auf die für die Bahngäste wichtigen Verspätungsintervalle konzentriert.

Metrik	Precision	Recall	F1-Score	Support
Klasse 0	0.88	0.99	0.93	105509
Klasse 1	0.40	0.10	0.16	9054
Klasse 2	0.34	0.05	0.08	3218
Klasse 3	0.39	0.06	0.11	1977
Klasse 4	0.52	0.43	0.47	4055
Klasse 5	0.55	0.31	0.39	1538
Klasse 6	0.57	0.37	0.45	577
Accuracy		0.85		125928
Macro Avg	0.52	0.33	0.37	125928
Weighted Avg	0.81	0.85	0.82	125928

Table 1: Ergebnisse des Classification Reports(Alfahel, 2024)

Metrik	Wert
F1-Score	0.85
Genauigkeit	0.85
Präzision	0.85
Recall	0.85

Table 2: Zusammenfassung der Modellbewertung(Alfahel, 2024)

	0	1	2	3	4	5	6
0	103969	685	91	46	542	127	49
1	7803	872	114	36	188	36	5
2	2381	363	154	62	234	14	10
3	1300	130	66	128	326	19	8
4	1957	92	31	52	1743	151	29
5	701	14	2	5	286	470	60
6	300	3	0	2	12	45	215

Table 3: Konfusionsmatrix der Vorhersagen des Modells(Alfahel, 2024)

6 Ergebnisse

Das RandomForest-Modell erzielte eine Gesamttreffergenauigkeit von 85 % auf den Testdaten (siehe Tabelle 2). Diese hohe Genauigkeit zeigt, dass das Modell in der Lage ist, den Verspätungstyp in den meisten Fällen korrekt vorherzusagen. Auch der F1-Score, der sowohl die Präzision als auch den Recall des Modells berücksichtigt, liegt bei 0,85, was auf eine ausgewogene Leistung des Modells in Bezug auf richtig positive Vorhersagen hinweist. Bei der detaillierten Betrachtung der Modellleistung nach Kategorien,




Figure 8: Wichtigkeit der Merkmale für die Vorhersage von Zugverspätungen im Random Forest-Modell(Alfahel, 2024)

wie in Tabelle 1 dargestellt, zeigt sich, dass die Klasse "0" (Verspätungen zwischen 0 und 4 Minuten) am besten vorhergesagt wird. Hier erreicht das Modell eine Präzision von 0,88, einen Recall von 0,99 und einen F1-Score von 0,93. Dies deutet darauf hin, dass das Modell sehr gut darin ist, diese Kategorie zu erkennen und korrekt zu klassifizieren. Für die anderen Kategorien ist die Modellleistung unterschiedlich stark ausgeprägt. Besonders die Kategorien "1" (5-10 Minuten), "2" (11-15 Minuten) und "3" (16-20 Minuten) weisen niedrigere Recall-Werte auf, was bedeutet, dass das Modell Schwierigkeiten hat, diese Verspätungstypen zuverlässig zu identifizieren. Beispielsweise liegt der Recall für die Kategorie "1" nur bei 0,10, was darauf hinweist, dass das Modell diese Klasse häufig fälschlicherweise als andere Klassen klassifiziert. Die Konfusionsmatrix in Tabelle 3 zeigt ebenfalls, dass viele Fälle, die in die Kategorien "1", "2" und "3" fallen, falsch zugeordnet werden. Zum Beispiel wurden von den 9.054 tatsächlichen Fällen in Kategorie "1" nur 872 korrekt klassifiziert, während 7.803 Fälle fälschlicherweise der Kategorie "0" zugeordnet wurden. Ähnliche Fehlklassifikationen sind in den Kategorien "2" und "3" zu beobachten, wo viele Fälle in die benachbarten Kategorien einsortiert wurden. Die Analyse der niedrigen Recall-Werte für diese mittleren Kategorien (siehe Tabelle 1) zeigt, dass das Modell seine Fähigkeit verbessern muss, Verspätungen in diesen Zeitspannen (5 bis 20 Minuten) präziser zu unterscheiden und zu klassifizieren. Ein weiterer wichtiger Aspekt der Analyse war die Optimierung der Hyperparameter des Modells. Die besten Ergebnisse wurden erzielt mit: "n_estimators": 1000, "n_features": 15, "min_samples_split": 40. Die Trainingszeit für das Modell betrug etwa 7988 Sekunden, was aufgrund der Komplexität des Modells und der durchgeführten Grid Search für die Hyperparameter-Optimierung zu erwarten war. (Alfahel, 2024)

7 Wichtigkeit der Merkmale

Figure 8 zeigt die Wichtigkeit der Merkmale für die Vorhersage von Zugverspätungen im Random Forest-Modell, inklusive der jeweiligen Anteile in Prozent. Die Zug-ID hat mit etwa 22% den größten Einfluss, gefolgt von PKP Intercity mit 20% und der Temperatur mit 15%. Diese Merkmale sind entscheidend, da sie systematische Verzögerungen und wet-

terbedingte Einflüsse erfassen. Auch Verbindungen tragen mit 10%, Wochentage mit 8% und Tageszeiten mit 7% erheblich zur Vorhersage bei, da sie das Verkehrsaufkommen und typische Verspätungsmuster widerspiegeln. Andere Merkmale wie der Bahnstationsname (ca. 5%) und die verschiedenen Zugbetreiber, die jeweils weniger als 2% ausmachen, haben hingegen einen geringeren Einfluss auf die Vorhersagegenauigkeit. (Alfahel, 2024)

8 Fazit

In dieser Arbeit wurde das Random Forest-Modell zur Vorhersage von Zugverspätungen basierend auf dem Polish Railroads Dataset untersucht, wobei eine Vorhersagegenauigkeit von 85 % erreicht wurde. Die wichtigsten Merkmale für die Vorhersage waren die Zug-ID, der Betreiber PKP Intercity und die Temperatur, da sie die Pünktlichkeit der Züge maßgeblich beeinflussen. Weitere relevante Merkmale waren die Tageszeit und Verbindungen, während die Zugbetreiber eine geringere Rolle spielten. Insgesamt zeigt sich, dass Random Forest ein effektives Modell zur Vorhersage von Zugverspätungen ist. Durch gezielte Anpassungen der Modellparameter und eine Verfeinerung der Datenverarbeitung könnte die Leistung weiter optimiert werden. Zusätzlich könnte die Einbeziehung weiterer Merkmale, wie spezifische Wetterbedingungen oder Ursachen für Verspätungen, die Genauigkeit insbesondere in mittleren Kategorien verbessern, indem das Modell komplexere Muster besser erkennt.

References

- Alfahel, Rouy (2024). *Train-Delay*. [abgerufen am 04.09.2024]. URL: <https://github.com/Royalfahel/Train-Delay.git>.
- Deutsche Bahn (2024). *Warum Züge manchmal ausfallen*. [abgerufen am 01.09.2024]. URL: <https://www.bahn.de/service/fahrplaene/infografik-warum-zuege-manchmal-ausfallen>.
- Hauck, Florian and Natalia Kliewer (2020). *Data Analytics in Railway Operations: Using Machine Learning to Predict Train Delays*. [abgerufen am 29.08.2024]. URL: https://link.springer.com/chapter/10.1007/978-3-030-48439-2_90.
- Shi, Rui et al. (2021). *Prediction and analysis of train arrival delay based on XGBoost and Bayesian optimization*. [abgerufen am 31.08.2024]. URL: <https://www.sciencedirect.com/science/article/pii/S1568494621004610>.
- Wikipedia (2024). *Random Forest*. [abgerufen am 02.09.2024]. URL: https://de.wikipedia.org/wiki/Random_Forest.
- ZDF Heute (2024). *Bahn Verspätung im Fernverkehr*. [abgerufen am 01.09.2024]. URL: <https://zdfheute-stories-scroll.zdf.de/bahn-verspaetung-fernverkehr/index.html>.

Eigenständigkeitserklärung

Hiermit erkläre ich, dass ich die vorliegende Arbeit selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt habe. Alle Stellen, die wörtlich oder sinngemäß aus veröffentlichten Schriften entnommen wurden, sind als solche kenntlich gemacht.